

# マルチメディア・インデキシング

情報学科CSコース情報システム(3年後期)

## 講義ノート —第10回—

マルチメディア情報検索  
(画像検索, ビデオ動画画像検索,  
Geminiアルゴリズム)

田中克己

## 基本的アイデア(1)

### マルチメディアオブジェクト間の距離

- マルチメディアオブジェクト  $O_A, O_B$
- 距離(非類似度)関数  $D(O_A, O_B)$

例: 等長の時系列データ  
ユークリッド距離

$$O_A = x_1 x_2 \dots x_n$$

$$O_B = y_1 y_2 \dots y_n$$

$$D(O_A, O_B) =$$

$$\sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2}$$

内容(コンテンツ)によるマルチメディアデータの探索

- 予測・診断・教育・仮説検証・データ発掘などに有用

GEMINI (Generic Multimedia Object Indexing)

時系列データとイメージデータを対象

## 基本的アイデア(2)

### 問合せ(Queries)

- 問合せもマルチメディアオブジェクト  $Q$
- 全体一致 (Whole Match)  
Qからある距離 $\varepsilon$ 内にあるオブジェクトを探索
- 部分(パターン)一致 (Subpattern Match)  
Qにマッチする部分をもつオブジェクトを探索

## 検索に関する要件

### 高速性

逐次スキャンに基づく距離計算は遅すぎる

### 正当性

- 正しい答えはすべて返す。  
(false dismissals (誤った棄却) がない!)
- 正しくない答 (false alarms (誤報)) は含んでも可。

### 小さなスペース。

動的: オブジェクトの追加・削除・更新が容易なこと。

## 全体一致質問のためのGEMINI

### quick-and-dirty test

答えでないオブジェクトを排除

### 空間アクセス法の利用

例: 株価の時系列データ  $S$ , 質問  $Q$   
距離関数  $D()$   
オブジェクトの特徴 (Feature):  $k$  個の数字  
 $F()$ : オブジェクトを  $k$  次元空間の点に写像  
 $F(Q)$  から距離  $\epsilon$  内にある点を検索  
実際のオブジェクトと  $Q$  の距離を計算し  
false alarms を排除

$$S = S[1]S[2]...S[l], Q = Q[1]Q[2]...Q[l]$$

$$D(S, Q) = \sqrt{\sum_{i=1}^l (S[i] - Q[i])^2}$$

## 全体一致質問のためのGEMINI


### F-index (Feature Index)

- $k$  次元空間の点集合の空間索引 (R 木や R\* 木を利用)

### F-index の探索

- 質問オブジェクト  $Q$  を特徴空間の点  $F(Q)$  に変換
- 空間アクセス法をもちいて,  $F(Q)$  から距離  $\epsilon$  内にある点を検索
- 本当の距離を計算し false alarms を排除

## 全体一致質問のためのGEMINI



データベース: 時系列データ  $S1, \dots, Sn$ ;  
各時系列データは特徴空間上の点  
許容度  $\epsilon$  の質問は, 半径  $\epsilon$  の球

## 特徴空間上の距離 $D_{\text{feature}}$

GEMINIが、全体一致質問に対してfalse dismissalsを起こさないためには、特徴関数  $F(\cdot)$  は次式を満たす：

$$D_{\text{feature}}(F(O_1), F(O_2)) \leq D(O_1, O_2)$$

十分条件：

$$D_{\text{feature}}(F(O_1), F(O_2)) \leq D(O_1, O_2)$$

質問オブジェクト  $Q$ 、答えとなるオブジェクト  $O$

近傍質問の許容距離  $\epsilon$

「 $O$ が $Q$ の答えならば、特徴空間で $O$ は $Q$ の答えとなる」ことを証明

すなわち、「 $D(Q, O) \leq \epsilon$ ならば $D_{\text{feature}}(F(Q), F(O)) \leq \epsilon$ 」を証明すればよい

$D(Q, O) \leq \epsilon$  と 条件  $D_{\text{feature}}(F(Q), F(O)) \leq D(Q, O)$  から、明らかに  $D_{\text{feature}}(F(Q), F(O)) \leq \epsilon$  が成立

## GEMINI

オブジェクト間の距離関数 $D(\cdot)$ を決定

1つ(又はそれ以上の)特徴抽出関数  $F(\cdot)$ を見つける

特徴空間での距離が以下になることを証明

$$D_{\text{feature}}(F(O_1), F(O_2)) \leq D(O_1, O_2)$$

空間アクセス法によって $k$ 次元特徴ベクトルを扱う

## 1次元時系列データのためのGEMINI

データベース：等長の時系列データの集合

質問：1つの時系列データ

答え：質問に類似する時系列データの集合

時系列データ $S, Q$

- $\text{Len}(S)$ :  $S$ の長さ
- $S[i:j]$ :  $S$ の  $i$ 番目から $j$ 番目までの部分系列
- $S[i]$ :  $S$ の  $i$ 番目の要素
- $D(S, Q)$ :  $S$ と $Q$ の距離

# 1次元時系列データのための GEMINI距離関数

## ユークリッド距離

- 多くの場合に有用
- 多くの類似度は、適当な変換の後、特徴ベクトルのユークリッド距離に帰着可能

## 他の距離関数 (Time-Warpingなど)

# ユークリッド距離をlower-boundする 特徴ベクトル

## 条件

- 元の距離関数をlower-boundする
- false alarmsができるだけ少ない

## 特徴抽出関数

- 平均  
全体平均, 前半平均, 後半平均, 最初の1/4の平均, ... (アダマール変換の係数に類似)
- 離散フーリエ変換 (Discrete Fourier Transform)

## 離散フーリエ変換(DFT)

- 信号  $\mathbf{x}$   
 $\vec{x} = [x_0, x_1, \dots, x_{n-1}]$
- $\mathbf{x}$ のn点離散フーリエ変換 ( $X_f$ は複素数)  
 $\vec{X} = [X_0, X_1, \dots, X_{n-1}]$   
$$X_f = 1/\sqrt{n} \sum_{i=0}^{n-1} x_i \exp(-j2\pi fi/n)$$
$$f = 0, 1, \dots, n-1$$
$$j = \sqrt{-1}$$
- 逆変換  
$$x_i = 1/\sqrt{n} \sum_{f=0}^{n-1} X_f \exp(j2\pi fi/n)$$
$$i = 0, 1, \dots, n-1$$

## Parsevalの定理

$$|x_0|^2 + |x_1|^2 + \dots + |x_{n-1}|^2 = |X_0|^2 + |X_1|^2 + \dots + |X_{n-1}|^2$$

DFTは線形変換なので,  $D(\mathbf{x}, \mathbf{y}) = D(\mathbf{X}, \mathbf{Y})$ .  
すなわち, DFTはユークリッド距離を保存する.

DFTの最初のk個の係数を特徴とすると

$$D_{\text{feature}}(\mathbf{F}(\mathbf{x}), \mathbf{F}(\mathbf{y})) =$$

$$|X_0|^2 + |X_1|^2 + \dots + |X_{k-1}|^2 \leq$$

$$|X_0|^2 + |X_1|^2 + \dots + |X_{n-1}|^2 =$$

$$|x_0|^2 + |x_1|^2 + \dots + |x_{n-1}|^2 = D(\mathbf{x}, \mathbf{y})$$



## ユークリッド距離を保存する変換

### 任意の正規直交変換

- 離散コサイン変換(DCT)
- ウェーブレット変換など

## サブパターン・マッチング (1D時系列の場合)

N個の時系列データ集合  $\{S_1, S_2, \dots, S_N\}$   
長さは可変

質問: 部分系列Q (長さ  $\text{Len}(Q) \geq w \geq 1$ ), 許容度  $\epsilon$

答え:  $(S_j, k)$   
 $D(Q, S_j[k: k + \text{Len}(Q) - 1]) \leq \epsilon$   
D: ユークリッド距離

逐次スキャン法よりもスペースの少ない方法

## DFT

DFTパッケージ

(Mathematicaパッケージ, Cパッケージなどあり)

DFTの性能の良さ

- 最悪のケース: 白色雑音の場合. つまり各  $x_i$  が  $x_{i-1}, x_{i+1}$  に対して完全に独立な場合.
- 実際の信号: random walks (brown noise) など前の値に依存.
- 実験結果:  $k=2$  または  $3$  で十分な結果を示す.

## ST Index (Subtrail Index)

I-naive法 (Index naive法)

時系列  $S_i$  を長さ  $w$  の部分系列に (重複を許して) 分割


長さ  $w$  の各部分系列を,  $w$  点DFT変換.

$W$  点DFTの係数  $k$  個を特徴関数値として利用

時系列  $S_i$  は, 特徴空間上で, trail (小径) として表現される.


trailの各点をすべて記憶 (R\*木などを利用)

## I-naive法




ウィンドウ幅  $w$   
 時系列データ  $S1$  を、最初から、 $k$  個ずつに区切る。  
 長さ  $k$  の部分系列を特徴空間に写像 (DFT の利用)  
 特徴空間で、 $S1$  は、点列 (小径) であらわされる。

## ST Index




Trail を subtrail に分割. 各 subtrail から MBR を形成.  
 MBR を階層的にグループ化し  $R^*$  木に格納.

## ST Index: short query の場合



質問: 長さ  $w$  の時系列データ. 特徴空間では点  $Q$ .  
 $Q$  から半径  $\epsilon$  の円と重なる MBR を検索.  
 False alarms を取り除く.

## ST Index: long query の場合



長い質問  $Q$ : 長さ  $w$  の  $p$  個の質問  $Q1, Q2$  ( $p=2$ ) に分割.  
 $Q1, Q2$  から半径  $\epsilon/\sqrt{p}$  の円と重なる MBR を検索.  
 検索された MBR の和集合をとる. False alarms を除く.